

Introduction à la théorie des valeurs extrêmes

Application à la classification

Aujourd'hui

Structure of the talk

- 1 Introduction : Classification et évènements rares
- 2 Théorie des valeurs extrêmes univariée
- 3 Éléments de théorie multivariée
- 4 Classification dans les régions extrêmes

Le problème de classification binaire

On observe une variable de caractéristiques $X \in \mathcal{X}$ et une étiquette $Y \in \{0, 1\}$. Un classifieur $g : \mathcal{X} \rightarrow \{0, 1\}$ prédit Y à partir de X .

$$(X_1, Y_1), \dots, (X_n, Y_n) \quad \text{observations d'apprentissage,} \quad \hat{Y} = g(X).$$

Exemple : continuité du réseau électrique

X regroupe la demande, la température et l'état du réseau ; $Y = 1$ signifie qu'une interruption survient dans l'horizon étudié. On cherche à prédire l'étiquette d'une nouvelle situation.

La question statistique porte sur de **nouvelles observations**, issues de la même loi que celle visée par la décision.

Le risque mesure les erreurs de prédiction

Avec la perte 0–1, chaque mauvaise prédiction coûte une unité :

$$\ell(g(x), y) = \mathbf{1}\{g(x) \neq y\}, \quad R(g) = \mathbb{E}[\ell(g(X), Y)] = \mathbb{P}\{g(X) \neq Y\}.$$

- ▶ Un **faux positif** prédit 1 alors que $Y = 0$.
- ▶ Un **faux négatif** prédit 0 alors que $Y = 1$.

Objectif de la classification

Choisir g pour rendre $R(g)$ aussi petit que possible. Le risque 0–1 accorde le même coût aux deux types d'erreurs.

La règle de Bayes : la meilleure décision en chaque x

Notons $\eta(x) = \mathbb{P}(Y = 1 \mid X = x)$. À caractéristiques $X = x$ fixées :

$$\mathbb{P}(g(X) \neq Y \mid X = x) = \begin{cases} \eta(x), & g(x) = 0, \\ 1 - \eta(x), & g(x) = 1. \end{cases}$$

On choisit la plus petite des deux erreurs conditionnelles :

$$g^*(x) = \mathbf{1}\{\eta(x) \geq \tfrac{1}{2}\}.$$

Lecture

Si $\eta(x) = 0,8$, prédire 1 donne 20 % d'erreur conditionnelle ; prédire 0 en donne 80 %.

Le risque de Bayes : une référence théorique

La règle g^* minimise le risque 0–1 parmi tous les classifieurs mesurables :

$$R^* = R(g^*) = \inf_g R(g) = \mathbb{E}[\min\{\eta(X), 1 - \eta(X)\}].$$

- ▶ Si $\eta(x)$ est proche de 0 ou de 1, la décision est relativement nette.
- ▶ Si $\eta(x)$ est proche de 1/2, une erreur reste probable même avec la règle optimale.

À distinguer

R^* est le minimum théorique pour la loi inconnue. L'excès de risque $R(g) - R^*$ mesure ce que le classifieur g perd par rapport à cette référence.

Le risque empirique : ce que voient les données

La loi de (X, Y) étant inconnue, on calcule la moyenne des erreurs observées :

$$\hat{R}_n(g) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}_{\{g(X_i) \neq Y_i\}}.$$

Par exemple, 8 erreurs sur 100 observations donnent $\hat{R}_{100}(g) = 0,08$.

Minimisation du risque empirique (ERM)

Pour une famille de modèles $\mathcal{G}$, on apprend $\hat{g} \in \arg \min_{g \in \mathcal{G}} \hat{R}_n(g)$.

Attention : une petite erreur d'entraînement ne garantit pas une petite erreur sur de nouvelles données. On évalue la généralisation sur des observations non utilisées pour apprendre.

Pourquoi le risque global peut négliger les extrêmes

Soit $A_t = \{x : \|x\| > t\}$ une région extrême et $q_t = \mathbb{P}(X \in A_t)$. Alors

$$R(g) = q_t R_t(g) + (1 - q_t) R_{\leq t}(g), \quad R_t(g) = \mathbb{P}(g(X) \neq Y \mid X \in A_t).$$

Le problème

Si q_t est petit, une grande erreur $R_t(g)$ change peu le risque global. Une méthode choisie par $\hat{R}_n$ peut donc être excellente sur les cas ordinaires et mauvaise lors des configurations extrêmes.

Exemple chiffré : le meilleur modèle dépend de la cible

Sur 10 000 cas de test, 200 appartiennent à la région extrême.

Modèle	Erreurs hors queue	Erreurs en queue	Risque global	Risque extrême
A	490/9 800	80/200	5,7 %	40 %
B	560/9 800	20/200	5,8 %	10 %

Deux choix cohérents avec deux objectifs

Le risque global préfère A de 0,1 point ; le risque en queue préfère B de 30 points. Si la décision porte sur les situations extrêmes, il faut sélectionner le modèle avec une métrique évaluée dans cette région.

Dans la queue, l'échantillon utile rétrécit

Parmi n observations, le nombre attendu de points dans A_t est nq_t .

Taille totale n	Part dans A_t	Nombre moyen en queue
10 000	2 %	200
10 000	0,1 %	10

Conséquence

Pour estimer le risque conditionnel, la précision dépend surtout du nombre $k \simeq nq_t$ d'observations extrêmes. Un seuil plus haut cible mieux la queue, mais laisse moins de données pour apprendre et valider.

Cas d'usage : infrastructures sous forte sollicitation

Réseau électrique

X : demande, température, charge des équipements.

Y : interruption dans l'horizon étudié.

Pourquoi la queue ? Les décisions d'exploitation lors des pics de demande dépendent de la performance précisément dans ces configurations.

Risque d'inondation locale

X : pluie, débit et niveau du cours d'eau.

Y : dépassement d'un niveau d'alerte en aval.

Pourquoi la queue ? La coïncidence de fortes valeurs peut compter davantage que la précision sur les journées ordinaires.

Risque extrême et taille effective

Pour $A_t = \{x : \|x\| > t\}$,

$$R_t(g) = \mathbb{P}\{g(X) \neq Y \mid X \in A_t\} = \frac{\mathbb{E}[\mathbf{1}\{g(X) \neq Y\} \mathbf{1}\{X \in A_t\}]}{\mathbb{P}(X \in A_t)}.$$

Estimateur empirique :

$$\hat{R}_t(g) = \frac{\sum_i \mathbf{1}\{g(X_i) \neq Y_i\} \mathbf{1}\{X_i \in A_t\}}{\sum_i \mathbf{1}\{X_i \in A_t\}}.$$

Nombre de termes utiles

$$N_t = \sum_i \mathbf{1}\{X_i \in A_t\} \simeq n \mathbb{P}(X \in A_t) \approx \sum_i \mathbf{1}\{X_i \in A_t\}.$$

Lorsque $\mathbb{P}(X \in A_t) \rightarrow 0$, il se peut que $N_t = 0 \rightsquigarrow$ il faut être capable de regarder au-delà des données.

Structure of the talk

- 1 Introduction : Classification et évènements rares
- 2 Théorie des valeurs extrêmes univariée
 - Cas particulier des queues lourdes
 - Estimation
 - Exemple de données de crue
- 3 Éléments de théorie multivariée
- 4 Classification dans les régions extrêmes

Pourquoi la fonction de répartition empirique ne suffit pas ?

Pour $X_1, \dots, X_n \sim F$, si on veut estimer un quantile d'ordre p , on peut utiliser la fonction de répartition empirique

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{X_i \leq x\}, \quad x \in \mathbb{R};$$

et résoudre $\hat{F}_n(q) = p$. Si $p > 1 - 1/n$ alors résoudre

$$\hat{F}_n(q) = p$$

fournira toujours $\hat{q}_n = \max(X_1, \dots, X_n)$.

Question

Comment estimer $\mathbb{P}(X > x)$ lorsque x est au-delà, ou presque au-delà, des observations ?

- ▶ On ne modélise pas toute la distribution.
- ▶ On impose une structure asymptotique dans la queue.

Pour $(X_i)_{i \geq 0}$ i.i.d. de même loi qu'une variable X , pour avoir des informations sur le "centre" de la distribution de X , il est naturel de regarder $\bar{X}_n$. On sait (si la variance est finie) que

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \mathcal{N}(0, 1).$$

Pour $(X_i)_{i \geq 0}$ i.i.d. de même loi qu'une variable X , pour avoir des informations sur le "centre" de la distribution de X , il est naturel de regarder $\bar{X}_n$. On sait (si la variance est finie) que

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \mathcal{N}(0, 1).$$

Si on veut regarder la queue de la distribution, on regarde $\max(X_1, \dots, X_n)$ plutôt que $\bar{X}_n$.

Pour $(X_i)_{i \geq 0}$ i.i.d. de même loi qu'une variable X , pour avoir des informations sur le "centre" de la distribution de X , il est naturel de regarder $\bar{X}_n$. On sait (si la variance est finie) que

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \mathcal{N}(0, 1).$$

Si on veut regarder la queue de la distribution, on regarde $\max(X_1, \dots, X_n)$ plutôt que $\bar{X}_n$.

Question

Est-ce qu'il existe des suites $(a_n)_{n \geq 0}$ et $(b_n)_{n \geq 0}$ et une loi $\mathcal{D}$ telles que

$$\frac{\max(X_1, \dots, X_n) - b_n}{a_n} \xrightarrow[n \rightarrow \infty]{\mathcal{L}} \mathcal{D}?$$

Fisher–Tippett–Gnedenko Theorem

Théorème : Domaine d'attraction du maximum

Soient $X_1, X_2, \dots$ des variables i.i.d. et

$$M_n = \max(X_1, \dots, X_n).$$

S'il existe $a_n > 0$ et $b_n \in \mathbb{R}$ tels que

$$\mathbb{P}\left(\frac{M_n - b_n}{a_n} \leq x\right) \xrightarrow{n \rightarrow \infty} G(x),$$

pour une loi non dégénérée G , alors G appartient à la famille des lois d'extrêmes généralisées (GEV) :

$$G_\gamma(x) = \exp\left\{-(1 + \gamma x)^{-1/\gamma}\right\}, \quad 1 + \gamma x > 0.$$

Fréchet

$$\gamma > 0$$

Queues lourdes (polynômes)

Gumbel

$$\gamma = 0$$

Queues légères (exponentielles)

Weibull

$$\gamma < 0$$

queues finies

Une fonction réelle f est dite à variation régulière d'indice α si

$$f(x) = x^\alpha L(x),$$

où L vérifie :

$$\frac{L(tx)}{L(t)} \rightarrow 1.$$

Ainsi

$$\frac{f(tx)}{f(t)} \rightarrow x^\alpha.$$

On note $f \in RV_\alpha$.

Variation régulière et domaine d'attraction

Soient $X_1, X_2, \dots$ des variables i.i.d. On note F leur fonction de répartition commune et $\bar{F} := 1 - F$ la fonction de survie.

Théorème

F appartient au domaine d'attraction de G_γ pour un $\gamma > 0$ si et seulement si $\bar{F}$ est à variation régulière d'indice $-\gamma$.

Interprétation

Loin dans la queue, changer d'échelle ne change plus la forme : la queue ressemble à une puissance.

Quantile et variation régulière

On définit la fonction quantile de queue

$$U(t) = F^{\leftarrow} \left(1 - \frac{1}{t} \right).$$

Si

$$\overline{F} \in RV_{-\alpha} \Rightarrow U \in RV_{1/\alpha}.$$

Autrement dit,

$$\frac{U(tx)}{U(t)} \rightarrow x^{1/\alpha}.$$


Pour une petite probabilité p et $\eta \in [0; 1]$, on a

$$q(p) = U(1/p) = U\left(\frac{\eta}{p\eta}\right) \approx U\left(\frac{1}{\eta}\right) \left(\frac{\eta}{p}\right)^{1/\alpha}.$$

Cette relation fonde les estimateurs de quantiles extrêmes.

Méthode d'estimation : Peaks Over Threshold

En pratique, on ne souhaite garder que les grandes valeurs observées pour que les valeurs du centre de la distribution ne polluent pas l'estimation de la queue.



On garde toutes les observations telles que

$$X_i > u.$$

On modélise ensuite les excès

$$Y_i = X_i/u \mid X_i > u.$$

Avantage

On ne garde que les données "utiles".

Inconvénient

On a souvent peu de données.

Pickands–Balkema–de Haan

Lorsque X est à queue lourde d'indice γ (donc $\gamma > 0$), on a

$$\mathbb{P}(X/u > t \mid X > u) \xrightarrow{u \rightarrow \infty} t^{-\gamma}, \quad t > 1.$$

La loi limite est appelée loi de Pareto d'indice γ .

Les variables Y_i construites par la méthode peak over threshold sont des réalisations de $X/u > t \mid X > u$

↪ On peut estimer γ !!!

Statistiques d'ordre et choix du seuil

Statistiques d'ordre

Pour un échantillon $X_1 \leq \dots \leq X_n$, les éléments de l'échantillon ordonné $X_{1:n} \leq \dots \leq X_{n:n}$ sont appelés statistiques d'ordre.

Pour $1 \leq k \leq n$, on appellera $X_{n-k:n}$ la k -ième statistique d'ordre.

Choix du seuil u

En pratique, on se fixe $1 \leq k \leq n$ et on choisit

$$u = X_{n-k:n}.$$

Motivations pour ce choix :

- ▶ Permet de garder une taille d'échantillon fixée à k , donc connue et non aléatoire
- ▶ Permet de réduire le nombre de seuils possibles
- ▶ À biais fixé, les estimateurs seuilés avec des statistiques d'ordre sont ceux de plus petites variances

Estimateur de Hill

On considère un échantillon $X_1 \leq \dots \leq X_n$, et $X_{1:n} \leq \dots \leq X_{n:n}$ les statistiques d'ordre. Soit $(k_n)_{n>0}$ une suite d'entiers. On définit l'estimateur de Hill par

$$\hat{\gamma}_k := \frac{1}{k} \sum_{i=1}^k \log \left(\frac{X_{n-k+i:n}}{X_{n-k:n}} \right).$$

Théorème

Si la suite $(k_n)_{n>0}$ vérifie

$$k_n \rightarrow \infty, \quad \frac{k_n}{n} \rightarrow 0.$$

alors sous des hypothèses techniques sur F (appelées variations régulières au second ordre) on a

$$\sqrt{k}(\hat{\gamma}_k - \gamma) \xrightarrow[k \rightarrow \infty]{\mathcal{L}} \mathcal{N}(0, \gamma^2).$$

On considère un échantillon $X_1, \dots, X_n$, et $X_{1:n} \leq \dots \leq X_{n:n}$ les statistiques d'ordre associées. Soit $(k_n)_{n>0}$ une suite d'entiers. On définit l'estimateur de Hill par

$$\hat{\gamma}_k := \frac{1}{k} \sum_{i=1}^k \log \left(\frac{X_{n-k+i:n}}{X_{n-k:n}} \right).$$

Compromis biais / variance à taille finie

- ▶ Augmenter k permet d'avoir plus de points, donc moins de variance mais plus de biais (avec le risque de quitter le régime extrême)
- ▶ Diminuer k réduit le biais mais augmente la variance car on a peu de points au-dessus de la k -ième statistique d'ordre.

Estimateur de Weissman

Soit $(p_n)_{n>0}$ une suite tendant vers 0. Pour estimer le quantile d'ordre p_n , on a vu que

$$q(p_n) = U\left(\frac{1}{p_n}\right) U\left(\frac{n}{k} \frac{k}{np_n}\right) \approx U\left(\frac{n}{k}\right) \left(\frac{k}{np_n}\right)^\gamma.$$

- ▶ $U\left(\frac{n}{k}\right)$ peut être estimé par $X_{n-k:n}$
On peut montrer que $X_{n-k:n}/U\left(\frac{n}{k}\right) \rightarrow 1$ en probabilité.
- ▶ On peut estimer γ avec l'estimateur de Hill.

Estimateur de Weissman

$$\hat{q}(p_n) := X_{n-k:n} \left(\frac{k}{np_n}\right)^{\hat{\gamma}_k}.$$

Estimateur de Weissman : Convergence

Soient une suite $(p_n)_n$ et l'estimateur de Weissman

$$\hat{q}(p_n) := X_{n-k:n} \left(\frac{k}{np_n} \right)^{\hat{\gamma}_k}.$$

Théorème

Si la suite $(k_n)_{n>0}$ vérifie

$$k_n \rightarrow \infty, \quad \frac{k_n}{n} \rightarrow 0.$$

et si

$$np_n = o(k_n) \quad \text{et} \quad \log(np_n) = o(\sqrt{k_n})$$

alors sous des hypothèses techniques sur F (appelées variations régulières au second ordre) on a

$$\frac{\sqrt{k}}{\log(k/(np_n))} \left(\frac{\hat{q}(p_n)}{q(p_n)} - 1 \right) \xrightarrow[k \rightarrow \infty]{\mathcal{L}} \mathcal{N}(0, \gamma^2).$$

Le théâtre des opérations : Corre (70)



Contexte

Dans le village de Corre, un lavoir est situé en bordure d'une rivière appelée le Cône. On se pose deux questions :

- ▶ Est-ce que le lavoir risque d'être inondé pendant les 10 prochaines années ?
- ▶ Si oui, quelle serait la hauteur de la digue à construire pour le protéger ?

Pour répondre à ces questions, on utilise des mesures quotidiennes de profondeur sur les années 2012 et 2013. (Données sur hubeau.eaufrance.fr)

Information de référence : le lavoir est à environ 2.5 mètres du fond du cours d'eau.

On note X_n les mesures de profondeurs journalières. Et on pose $Y_n = \log(X_n)$.


Question

On cherche un quantile q de la loi de x tel que $\mathbb{P}(X > q) < 1 - \frac{1}{3650}$.

Nous n'avons que 731 données (2012 était bissextile); il nous faut donc extrapoler la queue de la distribution de X .


Histogramme des log-profondeurs (renormalisées)

Histogramme normalisé des log-profondeur



Histogramme des log-profondeurs (renormalisées)

Histogramme normalisé des log-profondeur



Extrapolation Gaussienne

On cherche q tel que

$$\mathbb{P}(X > q) = 1 - \frac{1}{3650}.$$

On a remarqué qu'il semblait possiblement raisonnable de supposer $Y = \log(X)$ gaussien. Ainsi

$$\mathbb{P}(Y > \log(q)) = \mathbb{P}\left(\frac{Y - \mu_n}{\sigma_n} > \frac{\log(q) - \mu_n}{\sigma_n}\right)$$

avec μ_n et σ_n respectivement la moyenne et l'écart type empirique de Y . Donc $\frac{\log(q) - \mu_n}{\sigma_n}$ peut être choisi comme le quantile de la $\mathcal{N}(0, 1)$ d'ordre $1 - \frac{1}{3650}$. Cela donne

$$q = \exp\left(q_{\mathcal{N}(0,1)}\left(1 - \frac{1}{3650}\right)\sigma_n + \mu_n\right).$$

Sur les données, on obtient $q = 2,07$ m $\rightsquigarrow$ Aucun risque d'inondation, on est tranquille !


Oups ... la boulette




Méthodologie générale

- ▶ On choisit le nombre de points extrêmes k
- ▶ On estime l'indice des valeurs extrêmes, avec l'estimateur de Hill par exemple
- ▶ On estime notre quantile d'intérêt avec Weissman

Estimateur de Hill en fonction du nombres d'exès



Estimateur de Hill en fonction du nombres d'exès



On utilise l'estimateur de Weissman

$$\hat{q}(p) := X_{n-k:n} \left(\frac{k}{np} \right)^{\hat{\gamma}_k}$$

avec $\hat{\gamma}_k = 0.0145$ pour $k = 25$ et $p = 1 - \frac{1}{3650}$.

On obtient $\hat{q}(p) = 6,67$ m $\rightsquigarrow$ Il faut construire un grand mur... ou accepter que le lavoir fasse trempette de temps en temps.

Structure of the talk

- 1 Introduction : Classification et événements rares
- 2 Théorie des valeurs extrêmes univariée
- 3 Éléments de théorie multivariée
 - Variations régulières multivariées : définition intuitive
 - Variations régulières multivariées : en pratique
- 4 Classification dans les régions extrêmes

Variations régulières multivariées

On a vu que, dans le cas univarié, l'hypothèse centrale était la notion de variation régulière de la queue de distribution.

L'idée derrière sa généralisation est le passage en coordonnées polaires. Pour une variable aléatoire X dans $\mathbb{R}^d$, on considère le couple

$$\left(\|X\|, \frac{X}{\|X\|} \right).$$

Ainsi

- ▶ $\|X\| \in \mathbb{R}_+$ est la composante radiale de X
- ▶ $\frac{X}{\|X\|} \in S_{d-1}$ est la composante angulaire de X

Idée

Pouvoir utiliser la théorie des valeurs extrêmes univariée sur le rayon pour contrôler la **magnitude** des extrêmes et étudier la loi de l'angle pour savoir la **position/direction** des extrêmes.

Variations régulières, exemple dans $\mathbb{R}^2$






Figure – Variations régulières multivariées, modèle jouet

Variations régulières, exemple dans $\mathbb{R}^2$



Mesure spectrale : $\Theta_Z \sim \mathcal{U}(0, 2\pi)$

Mesure radiale : $\|(X, Y)\|_2 \sim \mathcal{P}_3$

Définition

Une variable aléatoire $X \in \mathbb{R}^d$ est dite à variations régulières multivariées s'il existe $\alpha > 0$ et une mesure μ sur S^{d-1} telle que pour tout ensemble $A \subset S^{d-1}$

$$\mathbb{P} \left(\left(\|X\|, \frac{X}{\|X\|} \right) \in [t, \infty] \times A \mid \|X\| > r \right) \xrightarrow[r \rightarrow \infty]{} t^{-\alpha} \mu(A).$$

μ est alors appelée mesure spectrale de X .

Mettre les marges sur une échelle commune

Pour des marginales continues F_j , la transformation de Pareto idéale est

$$Z_j = \frac{1}{1 - F_j(X_j)}, \quad j = 1, \dots, d.$$

Par cette transformation, on obtient

$$\mathbb{P}(Z_j > z) = z^{-1}, \quad z \geq 1.$$

En pratique

On estime chaque F_j avec les données, éventuellement en ajustant une loi de queue. La standardisation empêche une coordonnée de dominer le rayon uniquement à cause de son unité.

Décomposition radiale–angulaire

Dans l'orthant positif, pour $Z = (Z_1, \dots, Z_d)$:

$$R = \|Z\|_1 = \sum_{j=1}^d Z_j, \quad \Theta = \frac{Z}{R}, \quad Z = R\Theta.$$

L'angle appartient au simplexe

$$\mathbb{S}_+^{d-1} = \left\{ \theta \in [0, 1]^d : \sum_{j=1}^d \theta_j = 1 \right\}.$$

Lecture

R mesure la taille de l'événement ; Θ décrit la part de chaque coordonnée. Le choix de la norme fixe la définition opérationnelle de la région extrême.

Lire un angle en dimension 2

Ici $\Theta = (\Theta_1, 1 - \Theta_1)$. Si R est grand :

Θ	Configuration	Interprétation
$(1, 0)$	Z_1 domine	Extrême près du premier axe
$(0, 1)$	Z_2 domine	Extrême près du second axe
$(1/2, 1/2)$	$Z_1 \simeq Z_2$	Grandes valeurs simultanées

Exemple

$Z = (90, 10)$ et $Z' = (50, 50)$ ont tous deux $R = 100$, mais leurs angles $(0,9, 0,1)$ et $(0,5, 0,5)$ racontent des événements différents.

Après une mise à l'échelle $b(t)$ appropriée, une formulation est

$$t \mathbb{P}\left(\frac{X}{b(t)} \in A\right) \longrightarrow \mu(A), \quad A \subset \mathbb{R}_+^d \setminus \{0\}.$$


La mesure limite est homogène :

$$\mu(cA) = c^{-\alpha} \mu(A), \quad c > 0.$$

Conséquence géométrique

La masse extrême se décompose en une décroissance **radiale** de type Pareto et une mesure **angulaire** H qui décrit les directions fréquentes.

Variations régulières multivariées



Conditionnellement à $R > t$, la distribution de Θ tend, sous les hypothèses de régularité, vers une loi angulaire normalisée dérivée de H .

- ▶ Masse près des sommets : une coordonnée domine souvent.
- ▶ Masse près de l'intérieur : plusieurs coordonnées deviennent grandes ensemble.
- ▶ Deux populations peuvent avoir des rayons similaires et des angles extrêmes différents.

Dépendance asymptotique : le coefficient χ

Pour deux marginales continues, écrivons $U_j = F_j(X_j)$. On étudie

$$\chi = \lim_{u \uparrow 1} \mathbb{P}(U_1 > u \mid U_2 > u).$$

$$\chi > 0$$

Une valeur extrême de X_2 laisse une probabilité limite positive que X_1 soit aussi extrême.

$$\chi = 0$$

Les dépassements simultanés deviennent relativement rares au niveau asymptotique.

Exemple de lecture : deux classes, deux directions

Supposons des variables standardisées de dimension 2.

- Pour $Y = 0$, les observations extrêmes se concentrent près de $(1, 0)$.
- Pour $Y = 1$, elles se concentrent près de $(1/2, 1/2)$.

Une observation avec un grand rayon et un angle proche de $(1/2, 1/2)$ apporte alors un indice en faveur de la classe 1.

À retenir

Dans les extrêmes, la direction peut porter le signal de classification que la région centrale masque.

Structure of the talk

- 1 Introduction : Classification et évènements rares
- 2 Théorie des valeurs extrêmes univariée
- 3 Éléments de théorie multivariée
- 4 Classification dans les régions extrêmes

Le risque global donne peu de poids à la queue

Pour $A_t = \{x : \|x\| > t\}$ et $q_t = \mathbb{P}(X \in A_t)$, posons

$$R_t(g) = \mathbb{P}(g(X) \neq Y \mid X \in A_t).$$

Le risque 0–1 global vérifie

$$R(g) = q_t R_t(g) + (1 - q_t) R_{\leq t}(g).$$

Exemple

Si $q_t = 0,01$, une hausse de 20 points de l'erreur conditionnelle dans la queue n'ajoute que 0,2 point au risque global, toutes choses égales par ailleurs.

Estimer le risque conditionnel extrême

$$R_t(g) = \frac{\mathbb{E}[\mathbf{1}\{g(X) \neq Y\} \mathbf{1}\{\|X\| > t\}]}{\mathbb{P}(\|X\| > t)}.$$

Sur n observations indépendantes :

$$\hat{R}_t(g) = \frac{\sum_{i=1}^n \mathbf{1}\{g(X_i) \neq Y_i\} \mathbf{1}\{\|X_i\| > t\}}{\sum_{i=1}^n \mathbf{1}\{\|X_i\| > t\}}.$$

Taille d'échantillon utile

Le dénominateur compte les observations de la queue. Son ordre de grandeur est nq_t , souvent bien inférieur à n .

Hypothèse structurante : deux lois de classe à queue comparable

Passons à $Y \in \{0, 1\}$, avec $p = \mathbb{P}(Y = 1)$ et les lois conditionnelles F_1, F_0 . Pour $\sigma \in \{0, 1\}$, on suppose

$$t \mathbb{P}\left(\frac{X}{b(t)} \in A \mid Y = \sigma\right) \longrightarrow \mu_\sigma(A).$$

Les deux mesures μ_1 et μ_0 ont le même indice de queue α .

Pour définir le classifieur de Bayes extrême, on aimerait regarder quelque chose comme

$$\eta_t(x) = \mathbb{P}(Y = 1 | \|X\| > t, X = x), \quad x \in \mathbb{R}^d.$$

On va plutôt utiliser des coordonnées polaires, compatibles avec les variations régulières i.e.

$$\eta_t(r, \theta) = \mathbb{P}(Y = 1 | \|X\| > t, \|X\| > r, \frac{X}{\|X\|} = \theta), \quad \theta \in S^{d+1}, \quad r > t > 1.$$

En utilisant la relation de Bayes, il vient

$$\eta_t(r, \theta) = \frac{\mathbb{P}(\|X\| > r, \frac{X}{\|X\|} = \theta \|X\| > t, Y = 1) P_t(1)}{\sum_{y=0}^1 P_t(y) \mathbb{P}(\|X\| > r, \frac{X}{\|X\|} = \theta \|X\| > t, Y = y)}, \quad \theta \in S^{d+1}, \quad r > t > 1.$$

On note $P_t(y) = \mathbb{P}(Y = y | \|X\| > t)$ avec $y = 0$ ou 1 . Or, par hypothèse,

$$\mathbb{P}(\|X\| > r, \frac{X}{\|X\|} = \theta \|X\| > t, Y = 1) \xrightarrow[t \rightarrow \infty]{} r^\alpha \mu_1(\theta).$$

Le classifieur de Bayes est angulaire

On a alors

$$\eta_t(r, \theta) \xrightarrow{t \rightarrow \infty} \frac{r^\alpha \mu_1(\theta) P_\infty(1)}{r^\alpha \mu_1(\theta) P_\infty(1) + r^\alpha \mu_0(\theta) (1 - P_\infty(1))}.$$

Ainsi, asymptotiquement lorsque $t \rightarrow \infty$, on a

$$\eta_\infty(r, \theta) = \frac{\mu_1(\theta) P_\infty(1)}{\mu_1(\theta) P_\infty(1) + \mu_0(\theta) (1 - P_\infty(1))}.$$

$\leadsto$ on peut écrire $\eta_\infty(r, \theta) = \eta_\infty(\theta)$

Conclusion

Le classifieur de Bayes dépend uniquement de l'angle.

Le prédicteur de Bayes extrême est angulaire : en résumé

Dans le modèle limite,

$$\eta_{\infty}(\theta) = \mathbb{P}(Y_{\infty} = 1 \mid \Theta_{\infty} = \theta) = \frac{p\mu_1(\theta)}{P_{\infty}(1)\mu_1(\theta) + (1 - P_{\infty}(1))\mu_0(\theta)}.$$

Cela conduit à un prédicteur de Bayes de la forme

$$g_{\infty}^*(x) = \begin{cases} 1, & P_{\infty}(1)\mu_1(\Theta(x)) \geq (1 - P_{\infty}(1))\mu_0(\Theta(x)), \\ 0, & \text{sinon.} \end{cases}$$

Pourquoi le rayon disparaît-il à la limite ?

L'homogénéité commune donne la même décroissance radiale aux deux classes. Dans le rapport de Bayes, le facteur radial se simplifie :

$$\eta_{\infty}(r\theta) = \eta_{\infty}(\theta), \quad r > 0.$$

Réduction de dimension

La décision asymptotique peut porter sur $\Theta(X) \in \mathbb{S}_+^{d-1}$ au lieu de $X \in \mathbb{R}^d$: le classifieur limite est constant le long de chaque rayon.

Attention : à seuil fini, le rayon peut encore aider. Si les indices de queue des classes diffèrent, la classe à queue plus lourde peut dominer asymptotiquement.

Résultat : optimalité asymptotique

Supposons en plus une convergence uniforme des probabilités de classe :

$$\sup_{\theta \in \mathbb{S}_+^{d-1}} |\eta(t\theta) - \eta_\infty(\theta)| \longrightarrow 0.$$

Pour $L_t(g) = \mathbb{P}(Y \neq g(X) \mid \|X\| > t)$, le résultat de [1] établit que le risque de Bayes conditionnel converge vers le risque de Bayes limite :

$$L_t^* \longrightarrow L_{P_\infty}^*, \quad L_{P_\infty}^* = \mathbb{E}[\min\{\eta_\infty(\Theta_\infty), 1 - \eta_\infty(\Theta_\infty)\}].$$

Portée du résultat

Sous ces hypothèses, une règle angulaire atteint l'optimum asymptotique.

Trions les données par rayon décroissant : $R_{(1)} \geq \dots \geq R_{(n)}$. Pour une famille $\mathcal{G}_S$ de classifieurs angulaires :

$$\hat{L}_k(g) = \frac{1}{k} \sum_{i=1}^k \mathbf{1}\{g(\Theta(X_{(i)})) \neq Y_{(i)}\}, \quad \hat{g}_k \in \arg \min_{g \in \mathcal{G}_S} \hat{L}_k(g).$$

- ▶ Le seuil empirique est voisin du $(n - k)$ -ième rayon croissant.
- ▶ L'échantillon d'apprentissage pertinent contient k points.
- ▶ La cible est le risque dans la queue, pas le risque sur la population entière.

Pourquoi les fluctuations sont-elles de l'ordre de $1/\sqrt{k}$?

Dans une région A de probabilité $q \ll 1$, un indicateur $\mathbf{1}_A$ a une variance au plus q . Une borne de concentration locale pour une classe de complexité VC V a schématiquement la forme

$$\sup_A |\mathbb{P}_n(A) - \mathbb{P}(A)| \lesssim \sqrt{\frac{q\{V + \log(1/\delta)\}}{n}} + \frac{V + \log(1/\delta)}{n}.$$

Après division par q , le terme dominant vaut

$$\sqrt{\frac{V + \log(1/\delta)}{nq}} \simeq \sqrt{\frac{V + \log(1/\delta)}{k}}, \quad k \simeq nq.$$

Trois sources d'erreur en classification extrême

Pour une famille angulaire de dimension VC finie V , la borne schématique d'excès de risque contient

$$\underbrace{\sqrt{\frac{V + \log(1/\delta)}{k}} + \frac{V + \log(1/\delta)}{k}}_{\text{fluctuation statistique}} + \underbrace{\inf_{g \in \mathcal{G}_S} \{L_t(g) - L_t^*\}}_{\text{biais de modèle}}.$$

Pour viser le risque limite, il faut aussi contrôler

$$\underbrace{|L_t(g) - L_\infty(g)|}_{\text{biais EVT lié au seuil}}.$$

Compromis

Un seuil plus haut réduit le biais EVT, mais aussi k : l'incertitude augmente.

Choisir k : le régime intermédiaire

Pour une suite k_n :

$$k_n \longrightarrow \infty, \quad \frac{k_n}{n} \longrightarrow 0.$$

$$k_n \rightarrow \infty$$

Le nombre d'extrêmes croît ; la variance d'estimation peut diminuer.

$$k_n/n \rightarrow 0$$

Le seuil se déplace vers la queue ; le biais EVT peut diminuer.

Si le biais de modèle disparaît et les hypothèses de [1] sont satisfaites, le risque extrême du classifieur appris converge vers l'optimum limite.

Un protocole d'apprentissage extrême

- 1 Estimer les marginales et standardiser les coordonnées si nécessaire.
- 2 Calculer $R_i = \|Z_i\|$; définir une grille de valeurs de k .
- 3 Pour chaque k , garder les k plus grands R_i et calculer $\Theta_i = Z_i/R_i$.
- 4 Entraîner un modèle sur (Θ_i, Y_i) selon la perte voulue.
- 5 Choisir k et le modèle avec une validation ciblant la queue.
- 6 Rapporter une métrique conditionnelle à la région extrême et son incertitude.

Références principales



H. Jalalzai, S. Cléménçon, A. Sabourin.

On Binary Classification in Extreme Regions.

NeurIPS, 2018.



A. Aghbalou, A. Sabourin, F. Portier.

Sharp error bounds for imbalanced classification : how many examples in the minority class ?

AISTATS, 2024.



N. Goix, A. Sabourin, S. Cléménçon.

Learning the dependence structure of rare events.

ICML, 2015.



S. Coles.

An Introduction to Statistical Modeling of Extreme Values.

Springer, 2001.